VACV SI

Прогноз селективности молекул по структуре

AI B2B SAS 67

08.11.2026

Задача Kaggle

Мало измерений.

597 прогнозов SI.

320 строк train

597 строк test

Метрика MSE

Чем меньше MSE, тем лучше

Целевая величина

SI = CC50 / IC50

Активность против VACV и цитотоксичность
в одном отношении

2 210

публичных измерений SI

1 049

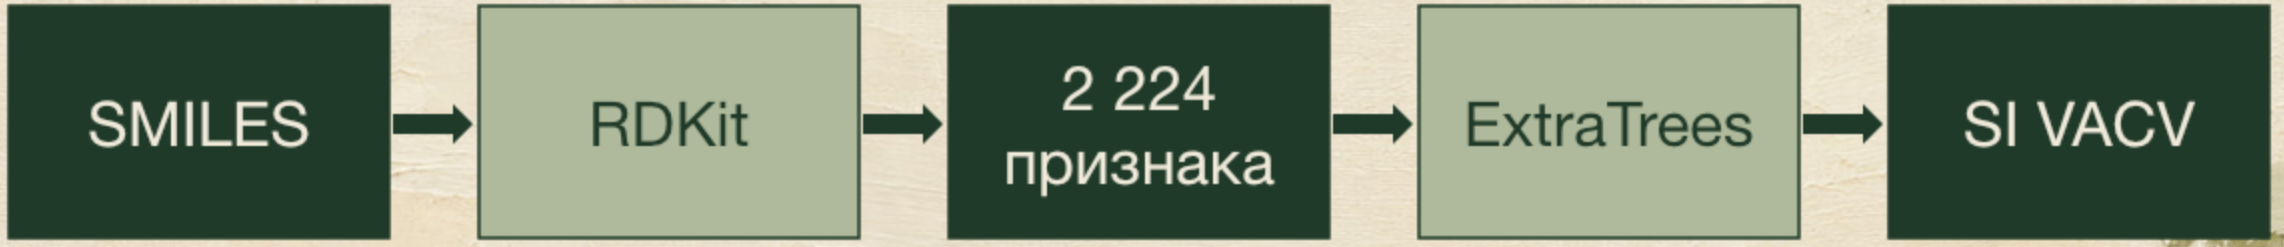
структур во внешней разметке

Внешние данные

ChEMBL, PubChem, PMC и Wiley.
Проверка формулы и происхождения.
216 структур совпадают с test.

Отсев: 605 непроверенных NCGC-строк
и 4 выброса ChEMBL с SI > 10 000.

От SMILES до submission



Структура молекулы

Основной фрагмент

Morgan + MACCS + дескрипторы

Обучение на log1p(SI)

expm1 и exact neighbor

Результат: 597 строк, колонки index и SI VACV

ExtraTrees на log1p(SI)

60 деревьев в одной модели.
3 seed для усреднения.
expm1 возвращает шкалу SI.

Логарифм сжимает разброс целевой величины.

Как работает одно дерево

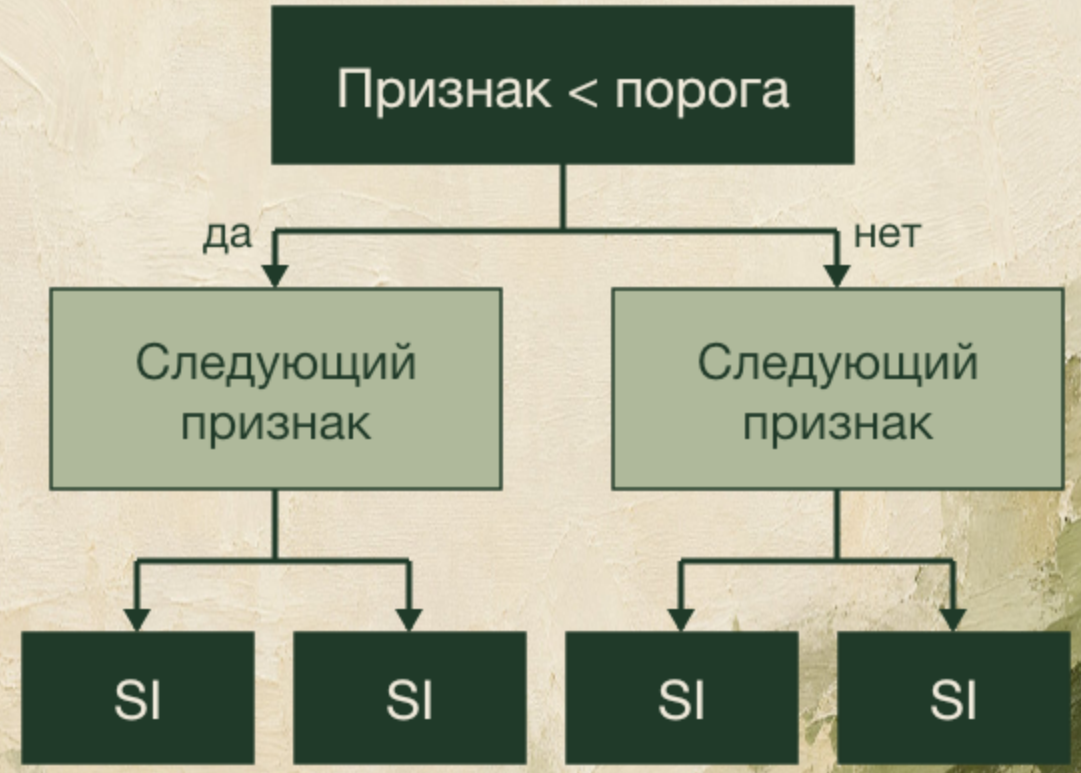


Схема дерева, без численных порогов

Две схемы проверки. Пять фолдов.

OOF-прогнозы получают только отложенные объекты

01

Canonical

Группы по InChIKey14. Совпадения не попадают в разные фолды.

02

Scaffold

Разделение по каркасам. Внешние совпадения исключаем из обучения.

03

Контроль хвоста

MSE целиком, без максимума и без top-7. Так видна роль крайних значений.

Что мы проверили

Выбор по валидации

01 **Fingerprints и деревья**

ExtraTrees на log1p(SI) вошёл в текущую версию решения.

02 **ChemBERTa и IC50/CC50**

Embeddings уступили fingerprints. Отношение двух прогнозов нестабильно.

03 **Гибрид с литературой**

Отдельная версия с более низким MSE. Сравним её с ML-финалом.

Результат на Kaggle

AI B2B SAS 67. 6-е место из 57 команд.

ML-финал

24 785,06119

Private MSE
Public MSE 211 415,38617

Прежний гибрид

19 064,26173

Private MSE
Public MSE 197 909,42299

Место команды: выбранный ML-финал. Гибрид: отдельная отправка. Kaggle, 08.11.2026.

Решение воспроизводится с нуля

01

Исходные данные

320 строк train и внешние метки.

02

Свой запуск

Notebook заново обучает ExtraTrees.

03

Проверка CSV

597 уникальных index. Прогнозы ≥ 0 и конечны.

04

Числовая сверка

Макс. разница $1{,}71 \times 10^{-13}$.

Локальная reconstructed MSE 80 742,92 служит только диагностикой.

Команда

AI B2B SAS 67



Ярослав Лихачёв

ML

Подготовка данных, обучение и валидация моделей



Данила Пшенников

CEO

Координация команды и презентация решения